

Śledzenie obiektów

Tomasz Kryjak

**Wydział EAIiB
Katedra Automatyki i Robotyki**

28.05.2018


✚ Co to jest śledzenie ?



AGH

Śledzenie

- ✦ Co to jest śledzenie ?
- ✦ Estymacja trajektorii obiektu poruszającego się na scenie (tj. przypisanie etykiet do poszczególnych obiektów).
- ✦ Oczywiście ten sam obiekt, ma mieć w trakcie obecności na scenie cały czas tą samą etykietę.



A co to jest obiekt ?

Obiekt – coś co jest interesujące w rozważanej aplikacji (ludzie, samoloty, samochody, krople wody itp.)

Czy śledzenie to temat ważny ?

Czy śledzenie to łatwe zadanie w automatycznych systemach wizyjnych ?

- ✦ nagły, szybki ruch obiektu,
- ✦ zmiana wyglądu obiektu,
- ✦ zmiana wyglądu sceny,
- ✦ obiekty, które nie są bryłami sztywnymi i zmieniają w trakcie śledzenia swój kształt (patrz człowiek),
- ✦ przesłaniania (obiekt/obiekt, obiekt/scena),
- ✦ ruch kamery,
- ✦ wymaganie działania w czasie rzeczywistym,
- ✦ zmiany oświetlenia na scenie,
- ✦ szum,
- ✦ redukcja informacji związana z przejściem z 3D do 2D (szeroko rozumiana).

Jak sobie z nimi radzić ?

Primo. Zastosować dobry algorytm.

Ograniczenia/założenia:

- ✦ ruch obiektów jest płynny,
- ✦ stała prędkość, stałe przyspieszenie,
- ✦ wiedza a priori o liczbie i rozmiarze obiektów, wygładzie, kształcie.


Algorytmów śledzenia obiektów jest wiele ...

Pytania różnicujące:

- ✦ Jaka reprezentacja obiektu jest najlepsza ?
- ✦ W jaki sposób modelować ruch, wygląd czy kształt obiektu ?
- ✦ Jakie cechy obrazu powinny zostać użyte ?

- ✦ punkt (środek ciężkości)
- ✦ proste figury geometryczne (prostokąt, elipsa) – łatwo modelować ruch np. transformacja afiniczna. Zwykle do brył sztywnych, ale nie tylko.
- ✦ sylwetka, kontur - złożone obiekty nie będące bryłami sztywnymi,
- ✦ przeguby (przykładowo części ciała człowieka)
- ✦ szkielet.

Reprezentacja obiektu - kształt



Reprezentacja obiektu - wygląd

- ✚ rozkłady gęstości prawdopodobieństwa wyglądu obiektu.
 - ▶ parametryczne: Gaussian, Mixture of Gaussian.
 - ▶ nieparametryczne: okno Parzen'a, histogramy.
- ✚ wzorce
- ✚ aktywne modele wyglądu:
 - ▶ jednoczesne modelowanie kształtu i wyglądu,
 - ▶ kształt jest określony jako zbiór punktów charakterystycznych (każdy ma wektor cech np. kolor, teksturę, jasność, amplitudę gradientu).
 - ▶ w fazie uczącej model jest przygotowywany na podstawie zbioru uczącego (np. PCA).
- ✚ modele wielowidokowe.

Bardzo ważna sprawa. Cechy powinny w sposób (względnie) unikalny opisywać dany obiekt.

Przykłady:

- ✚ kolor,
- ✚ krawędzie (wykrycie konturów) – mniej wrażliwe od koloru na zmiany oświetlenia,
- ✚ przepływ optyczny,
- ✚ tekstura.

Co najmniej na jednej ramce, czasem na każdej (śledzenie przez detekcję) trzeba wykryć obiekty, które mamy zamiar śledzić

Przykłady metod:

- ✚ detekcja punktów charakterystycznych (Harris, SIFT, SURF, KLT),
- ✚ odejmowanie tła (segmentacja obiektów pierwszoplanowych),
- ✚ segmentacja (inne metody wyodrębniania interesujących nas obiektów),
- ✚ uczenie maszynowe (np. klasyfikator neuronowy),
- ✚ “ręczne wskazanie”.

Śledzenie oparte na analizie rozkładu prawdopodobieństwa pewnej cechy na obrazie. Przykładowo barwa (H – hue) z przestrzeni HSV. Inaczej mówiąc – prawdopodobieństwo, że obiekt znajduje się w danej lokalizacji.

Algorytm iteracyjny – znajdowanie maksimum funkcji gęstości (największego prawdopodobieństwa).

Mean shift – średnie przesunięcie. Nazwa dość dobrze charakteryzuje działanie. W pewnym obszarze obliczany jest środek ciężkości punktów, a następnie aktualny środek obszaru jest przesuwany do znalezionej środka ciężkości.

Mamy zbiór punktów $x_i, i = 1 \dots N$ oraz środek obszaru y_0 . Wektor *mean shift* dany jest wzorem:

$$M(y) = \frac{1}{N} \sum_{i=1}^N x_i - y_0 \quad (1)$$


Uwaga. Takie rozwiązanie zakłada, że waga poszczególnych punktów w rozważanym obszarze jest taka sama, co niekoniecznie może być pożądane.

Ale zawsze możemy wprowadzić wagi ...

$$M(y) = \frac{1}{N} \sum_{i=1}^N \frac{w_i(y_0) \cdot x_i}{w_i(y_0)} - y_o \quad (2)$$

Przykładowo waga może być zależna od odległości rozpatrywanego punktu od środka y_0 (im dalej tym punkt mniej ważny).

Interpretacja graficzna *mean shift*



Maksymalnie uproszczony opis:

- ➊ wybór obiektu śledzonego (np. ręczny),
- ➋ ekstrakcja cech wzorca (funkcja gęstości rozkładu prawdopodobieństwa),
- ➌ ekstrakcja cech kandydata,
- ➍ określenie podobieństwa wzorca i kandydata (potrzebujemy funkcję),
- ➎ wyliczenie nowych współrzędnych kandydata,
- ➏ stop lub powrót do 3.

Czy wszystkie piksele w oknie powinny być tak samo ważne ?


Zakłada się, że ważniejsze są piksele w środku. Dlatego wyznacza się jądro (*kernel*) np. Gaussa, Epanechnikova, kwadratowe, cosinusowe, czy trójkątne.

Jądro trójkątne:

$$K(u) = 1 - \|u\|, \quad \|u\| < 1 \quad (3)$$

u stosunek odległości danego punktu od środka obszaru do długości promienia okręgu wpisanego w dany obszar.

Jądro o rozmiarze 30×30



Oszacowanie gęstości jądra

Mamy N punktów x_i w przestrzeni R^2 (w naszym obszarze zainteresowania).

Wykorzystując wcześniej przedstawione jądro, możemy zapisać funkcję gęstości w punkcie (x) jako:

$$f(x) = \frac{1}{n} \sum_{i=1}^n K(\|x - x_i\|^2) \quad (4)$$

Różniczkujemy:

$$\nabla f(x) = \frac{2}{n} \sum_{i=1}^n (x - x_i) K'(\|x - x_i\|^2) \quad (5)$$

Oznaczamy $-K'(x)$ poprzez $g(x)$. Wtedy:

$$\nabla f(x) = \frac{2}{n} \sum_{i=1}^n (x_i - x) g(\|x - x_i\|^2) \quad (6)$$

Przekształcając:

$$\nabla f(x) = \frac{2}{n} \sum_{i=1}^n [g(\|x - x_i\|^2)] \left[\frac{\sum_{i=1}^n x_i g(\|x - x_i\|^2)}{\sum_{i=1}^n g(\|x - x_i\|^2)} - x \right] \quad (7)$$

Pierwszy człon to gradient jądra, a drugi to tzw. wektor *mean-shift* (wspomniany wcześniej).

Jeśli mamy wzorzec (obszar z ramki $t - 1$) i kandydata (obszar z ramki t), to musimy je porównać. Może to być tzw. współczynnik Bhattacharyya dany jako:

$$\rho(y) = \sum_{u=1}^m \sqrt{(p_u(y)q_u)} \quad (8)$$

gdzie: q – wzorzec (histogram), $p(y)$ – kandydat w punkcie y (też histogram).

Jak to działa ?

Na początku dokonujemy inicjalizacji śledzenia tj. określamy jądra (i jego gradient) oraz określamy funkcję gęstości prawdopodobieństwa. Stosujemy histogram HSV, przy czym uwzględniamy wagi wynikające z funkcji jądra.

Formalnie:

$$q_u = C \sum_{i=1}^N K(\|x_i\|^2) \delta[b(x_i) - u] \quad (9)$$

gdzie: u – kolejna wartość barwy, C – współczynnik normalizujący (suma współczynników jądra). Finalnie otrzymujemy znormalizowany histogram.

Wyznaczamy funkcję gęstości prawdopodobieństwa dla kandydata (znormalizowany histogram):

$$p_u(y) = C_h \sum_{i=1}^N K(\|y - x_i\|^2) \delta[b(x_i) - u] \quad (10)$$

gdzie: u – kolejna wartość barwy, C_h – współczynnik normalizujący (suma współczynników jądra), y – środek obszaru.

Porównujemy histogramy

$$\rho(y) = \sum_{u=1}^m \sqrt{(p_u(y)q_u)} \quad (11)$$

Szereg Taylora (dla otoczenia y_0)

$$\rho(p(y, q)) \approx \frac{1}{2} \sum_{u=1}^m \sqrt{(p_u(y_0)q_u)} + \frac{1}{2} \sum_{u=1}^m p_u(y) \sqrt{\frac{q_u}{p_u(y_0)}} \quad (12)$$

Pierwszy człon nie zależy od y , czyli nie jest dla nas ciekawy, bo ostatecznie chodzi nam o maksymalizację wyrażenia w zależności od y .

Podstawiamy wzór na $p_u(y)$

$$\rho(p(y, q)) \approx \frac{1}{2} \sum_{u=1}^m \sqrt{(p_u(y_0)q_u)} + \frac{C_h}{2} \sum_{i=1}^N w_i K(\|u - x_i\|^2) \quad (13)$$

gdzie:

$$w_i = \delta[b(x_i) - u] \sqrt{\frac{q_u}{p_u(y_0)}} \quad (14)$$

Zatem maksymalizujemy skrajnie prawy człon. Do tej maksymalizacji używamy metody *mean shift*.

$$y_1 = \frac{\sum_{i=1}^N x_i w_i g(\|y - x_i\|^2)}{\sum_{i=1}^N w_i g(\|y - x_i\|^2)} \quad (15)$$

A kiedy kończmy ?

✚ $\|y_1 - u_0\|^2 < \epsilon,$

✚ maksymalna liczba iteracji.

KLT to jeden ze starszych algorytmów śledzenia obiektów. Nazwa pochodzi od nazwisk twórców: Takeo Kanade, Bruce'a Lucasa oraz Carlo Tomasi. Jego pierwsza wersja została zaprezentowana w pracy „An Iterative Image Registration Technique with an Application to Stereo Vision” z roku 1981, a pewne ulepszenia zostały opisane w artykule „Detection and Tracking of Point Features” z roku 1991.

Idea opiera się na śledzeniu punktów charakterystycznych tj. wyliczaniu tzw. rzadkiego przepływu optycznego. Operacje przeprowadzane są na obrazach w odcieniach szarości.

Jeśli założymy, że chcemy śledzić położenie pikseli z ramki na ramkę to na obrazie znajdziemy „lepszych” i „gorszych” kandydatów.

Intuicyjnie. Na pewno złe będą jednorodne powierzchnie. Podobnie na krawędziach trudno dokonać jednoznacznego przypisania.

Najlepszym kandydatem wydają się być **narożniki**.

Czy można to wykazać ? (1)

Mamy obraz I , zbiór dopuszczalnych przekształceń $W(x, p)$ (x – lokalizacja, p – parametry przekształcenia) oraz fragment obrazu z poprzedniej ramki $T(x)$ – otoczenie punktu x .

błąd (SSD) $\rightarrow \sum_x [I(W, x, p) - T(x)]^2$

inkrementalne przesunięcie $\rightarrow \sum_x [I(W, x, p + \delta p) - T(x)]^2$

linearyzacja $\rightarrow \sum_x [I(W, x, p + \Delta p) + \nabla I \frac{\partial W}{\partial p} \Delta p - T(x)]^2$

$\nabla I = [\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y}]$, $W(x, p)$ – Jakobian przekształcenia.

Czy można to wykazać ? (2)

Obliczamy pochodną z wyrażenia po Δp :

$$2 \cdot \sum_x [\nabla I \frac{\partial W}{\partial p}]^T [I(W, x, p + \Delta p) + \nabla I \frac{\partial W}{\partial p} \Delta p - T(x)]$$

Przyrównujemy do zera:

$$\Delta p = H^{-1} \sum_x [\nabla I \frac{\partial W}{\partial p}]^T [T(x) - I(W, x, p + \Delta p)]$$

gdzie H – Hessian: $H = \sum_x [\nabla I \frac{\partial W}{\partial p}]^T [\nabla I \frac{\partial W}{\partial p}]$.

Czy można to wykazać ? (3)

Jeśli nasze śledzenie sprowadza się do iteracyjnego obliczania Δp , to stabilność procedury zależy głównie od obliczania odwrotności Hessianu.

Zatem pożądanym jest aby: $\lambda_1 \gg 0$ oraz $\lambda_2 \gg 0$.

A co to oznacza w praktyce ??

Przykład

Założmy, że nasze przekształcenie to prosta translacja.

Wtedy:

$$W(x, p) = \begin{bmatrix} x_1 + p_1 \\ x_2 + p_2 \end{bmatrix} \quad (16)$$

$$\frac{\partial W}{\partial p} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (17)$$

$$H = \sum_x \left[\nabla I \frac{\partial W}{\partial p} \right]^T \left[\nabla I \frac{\partial W}{\partial p} \right] = \sum_x \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{\partial I}{\partial x} \\ \frac{\partial I}{\partial y} \end{bmatrix} \left[\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y} \right] \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (18)$$

$$H = \sum_x \begin{bmatrix} \left(\frac{\partial I}{\partial x} \right)^2 & \frac{\partial^2 I}{\partial x \partial y} \\ \frac{\partial^2 I}{\partial x \partial y} & \left(\frac{\partial I}{\partial y} \right)^2 \end{bmatrix} \quad (19)$$

Analizujemy wartości własne λ_1 i λ_2 :

- ✦ $\lambda_1 \sim \lambda_2$ i obie małe – obszar jednorodny,
- ✦ $\lambda_1 \gg \lambda_2$ – krawędź pozioma,
- ✦ $\lambda_2 \gg \lambda_1$ – krawędź pionowa,
- ✦ $\lambda_1 \sim \lambda_2$ i obie duże – narożnik.

Uwaga. Proszę skojarzyć metodę z detekcją narożników Harrisa.